Học không gian trạng thái chọn lọc thích ứng miền cho giải mã EEG tưởng tượng vận động liên chủ thể

[Tên] [Họ][a,*]

[a][Khoa], [Tên đầy đủ của cơ quan], [Địa chỉ], [Thành phố], [Mã bưu chính], [Quốc gia]

Tóm tắt

Giải mã điện não đồ tưởng tượng vận động (MI-EEG) liên chủ thể gặp khó khăn do tỉ số tín hiệu trên nhiễu thấp, dữ liệu có nhãn khan hiếm, và độ dịch chuyển phân phối lớn giữa các chủ thể và các phiên ghi. Nghiên cứu này đề xuất SSM-DAN, một mạng không gian trạng thái chọn lọc thích ứng miền, kết hợp khối tích chập đa thang với các khối không gian trạng thái chọn lọc hai chiều để nắm bắt cả mẫu thời gian cục bộ lẫn tầm xa, đồng thời giảm độ dịch chuyển giữa các chủ thể bằng căn chỉnh phân cấp, gồm một lớp chuẩn hóa nguồn–đích được học và thích ứng tại thời điểm kiểm thử không cần nhãn. Khung phương pháp được đánh giá trên ba bộ dữ liệu MI-EEG công khai theo giao thức kiểm định bỏ-một-chủ-thể (leave-one-subject-out) với các phiên huấn luyện, thích ứng và kiểm thử được tách theo thứ tự thời gian. SSM-DAN đạt độ chính xác trung bình 76,12% trên BCI Competition IV-2a, 84,09% trên BCI Competition IV-2b và 84,33% trên Zhou2016. Các nghiên cứu loại bỏ thành phần (ablation), thực hiện thêm trên tập OpenBMI gồm 54 chủ thể, cho thấy đóng góp của từng thành phần thích ứng phụ thuộc vào bộ dữ liệu, và tham chiếu Riemann cần được ước lượng lại khi năng lượng tín hiệu thay đổi giữa các phiên. Kết quả cho thấy việc kết hợp mô hình không gian trạng thái chọn lọc với căn chỉnh phân cấp được học giúp cải thiện giải mã MI liên chủ thể mà không cần nhãn của chủ thể đích.

Từ khóa: tưởng tượng vận động, điện não đồ, giao diện não–máy tính, mô hình không gian trạng thái chọn lọc, Mamba, thích ứng miền, thích ứng tại thời điểm kiểm thử

*Tác giả liên hệ.

Email address: dinhmanhcuong2003@gmail.com ([Tên] [Họ])

1. Giới thiệu

Giao diện não–máy tính dựa trên tưởng tượng vận động (MI-BCI) giải mã ý định vận động từ điện não đồ (EEG) không xâm lấn, phục vụ phục hồi chức năng, giao tiếp và điều khiển. Các mẫu mất đồng bộ và đồng bộ liên quan đến sự kiện mà MI-BCI dựa vào thường yếu, không dừng, và khác nhau giữa các chủ thể cũng như giữa các phiên ghi của cùng một chủ thể [1]. Vì vậy, một bộ giải mã huấn luyện trên những người dùng có sẵn thường suy giảm hiệu năng trên người dùng mới, trong khi việc hiệu chuẩn từng người dùng mới bằng các lần thử có nhãn vừa tốn thời gian vừa gây mệt mỏi [2]. Giảm hoặc loại bỏ bước hiệu chuẩn có nhãn này do đó là một yêu cầu cốt lõi để MI-BCI có thể dùng trong thực tế.

Các bộ giải mã MI ban đầu đi theo quy trình học máy cổ điển. Lọc mẫu không gian chung (CSP) [3] và phiên bản dải lọc FBCSP [4], phương pháp thắng cuộc thi BCI Competition IV, trích xuất đặc trưng công suất dải tần qua các bước thiết kế thủ công, riêng cho từng chủ thể, rồi đưa vào một bộ phân loại tuyến tính. Về sau, học sâu thay thế các bước này bằng học đặc trưng đầu–cuối: ShallowConvNet và DeepConvNet [5] cùng mạng gọn nhẹ EEGNet [6] học trực tiếp các bộ lọc phổ và không gian từ EEG thô. Các mô hình sau đó mở rộng ngữ cảnh thời gian: EEG Conformer thêm cơ chế tự chú ý vào khối tích chập [7], ATCNet kết hợp chú ý với mạng tích chập thời gian (TCN) giãn [8], và TCFormer ghép tích chập đa thang, Transformer và TCN [9]. Tuy nhiên, tự chú ý có chi phí bậc hai theo độ dài chuỗi [10] và cần nhiều dữ liệu hơn mức các bộ EEG thường có. Gần đây, các mô hình không gian trạng thái (SSM), từ S4 có cấu trúc [11] đến Mamba chọn lọc [12], nổi lên như một lựa chọn thay thế có chi phí tăng tuyến tính theo độ dài chuỗi; trong mô hình hóa ngôn ngữ, Mamba đạt hoặc vượt Transformer có kích thước tương đương, đồng thời cho thông lượng sinh cao hơn nhiều lần [12]. Sau đó, MI-Mamba và một mạng Mamba không gian–thời gian đã kết hợp SSM với tích chập để giải mã MI [13, 14]. Dù đa dạng về kiến trúc, các phương pháp này đều được huấn luyện trên dữ liệu nguồn và áp dụng nguyên trạng cho người dùng mới, nên hiệu năng phụ thuộc vào mức độ tập huấn luyện đại diện cho từng người dùng.

Một hướng nghiên cứu bổ sung nhằm giảm sự phụ thuộc này vào tập huấn luyện và vào việc hiệu chuẩn có nhãn cho từng người dùng. Các mô hình nền tảng (foundation model) cho EEG, được tiền huấn luyện trên kho dữ liệu lớn và đa dạng, chẳng hạn khoảng 2.500 giờ EEG của LaBraM [15, 16], là một hướng nhiều tiềm năng, nhưng đòi hỏi thu thập và chuẩn hóa các bộ

dữ liệu lớn, không đồng nhất, và thường vẫn cần tinh chỉnh bằng dữ liệu có nhãn của tác vụ đích. Chuyển giao giữa các chủ thể trong cùng một tác vụ là một lựa chọn nhẹ hơn. Tổng quát hóa miền học từ nhiều chủ thể nguồn các đặc trưng có thể dùng cho chủ thể chưa thấy, nhờ đó người dùng mới có thể sử dụng ngay mà không cần hiệu chuẩn [17, 18, 19]; tuy nhiên, do chủ thể đích không bao giờ được quan sát, độ dịch chuyển riêng của chủ thể đó không thể được bù trừ. Thích ứng miền khắc phục hạn chế này bằng cách sử dụng thêm EEG không nhãn của chủ thể mới. Dữ liệu này không cần gán nhãn cho bất kỳ lần thử nào, khiến thích ứng miền trở thành một hướng thiết thực để điều chỉnh bộ giải mã theo từng người dùng mà không cần phiên hiệu chuẩn có nhãn. Để căn chỉnh đặc trưng nguồn và đích, độ sai khác trung bình cực đại (MMD), được DAN đưa vào mạng sâu dưới dạng đa nhân [20], là một trong những tiêu chí được sử dụng rộng rãi nhất nhờ tính phi tham số và tối ưu ổn định, và cũng được dùng trong các mô hình EEG như RMETNet [21]. Huấn luyện đối kháng với bộ phân biệt miền [22, 23] và căn chỉnh dựa trên nguyên mẫu lớp [24] cung cấp các mục tiêu bổ trợ. Việc căn chỉnh cũng có thể được thực hiện bên trong mạng thông qua các lớp chuẩn hóa: trong thích ứng miền thị giác, AutoDIAL [25] đề xuất các lớp căn chỉnh miền học mức độ trộn giữa thống kê nguồn và đích khi chuẩn hóa, một ý tưởng là nguồn cảm hứng cho cơ chế chuẩn hóa ở mức đặc trưng trong nghiên cứu này.

Bên cạnh mức đặc trưng, sự khác biệt giữa các chủ thể còn thể hiện ngay trên tín hiệu thô: ma trận hiệp phương sai giữa các kênh EEG, phản ánh cả giải phẫu đầu lẫn cách đặt điện cực, khác nhau rõ rệt giữa các người. Điều này gợi ý căn chỉnh chính tín hiệu trước khi đưa vào mạng. Hình học Riemann, coi ma trận hiệp phương sai của mỗi lần thử là một điểm trên đa tạp các ma trận đối xứng xác định dương, đã chứng tỏ hiệu quả trong giải mã MI [26]. Dựa trên đó, Zanini và cộng sự đề xuất căn chỉnh Riemann (RA), đưa tâm hiệp phương sai của mỗi chủ thể về ma trận đơn vị bằng trung bình Riemann không cần nhãn của chủ thể đó [27]. Tuy nhiên, mức cải thiện độ chính xác do RA mang lại có thể khác nhau giữa các bộ dữ liệu, và có xu hướng rõ rệt hơn khi phép căn chỉnh đồng thời làm tăng sự tách biệt giữa các lớp.

Vì vậy, chúng tôi đề xuất SSM-DAN, một mạng không gian trạng thái chọn lọc với thích ứng phân cấp không cần nhãn cho giải mã MI liên chủ thể, được thiết kế để mô hình hóa hiệu quả động học thời gian của MI-EEG đồng thời thích ứng với từng người dùng mới mà không cần hiệu chuẩn có nhãn. Các đóng góp chính gồm:

- một bộ giải mã nắm bắt cả mẫu phổ–không gian cục bộ lẫn phụ thuộc thời gian tầm xa của MI-EEG với chi phí tăng tuyến tính theo độ dài lần thử;
- một chiến lược thích ứng phân cấp giảm độ dịch chuyển giữa các chủ thể ở mức tín hiệu, đặc trưng và quyết định, chỉ dùng EEG không nhãn của người dùng mới; và
- đánh giá bỏ-một-chủ-thể theo thứ tự thời gian trên ba bộ dữ liệu công khai, trong đó nhãn đích được loại khỏi huấn luyện, thích ứng và chọn mô hình, và mọi phương pháp so sánh được huấn luyện lại trong cùng điều kiện.

2. Phương pháp

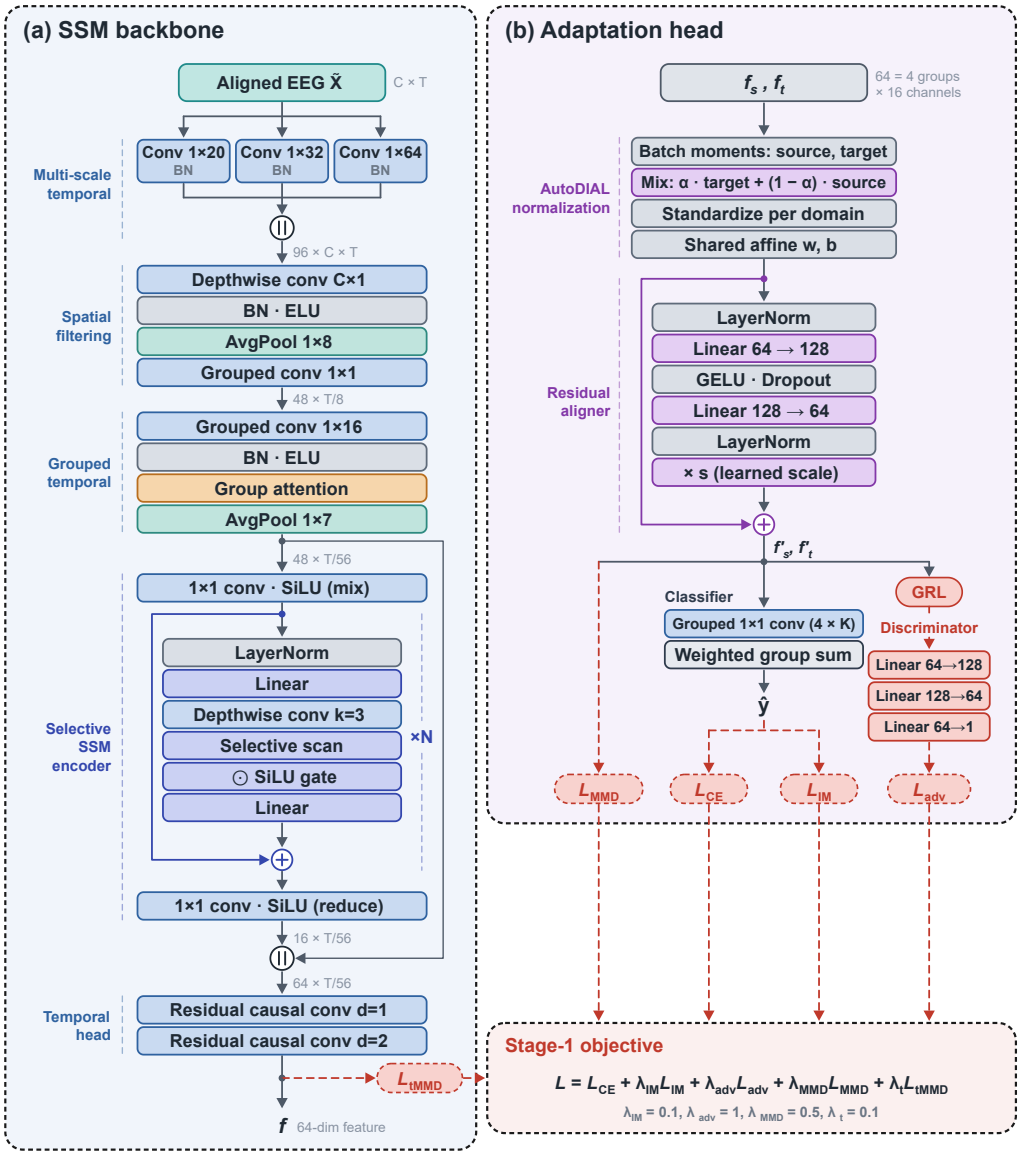
SSM-DAN gồm hai phần (Hình 1) và được huấn luyện qua hai giai đoạn (Hình 2). Bộ mã hóa EEG kết hợp tích chập đa thang cho đặc trưng phổ–không gian cục bộ, các khối không gian trạng thái chọn lọc hai chiều cho động học tầm xa, và một đầu hợp nhất tích chập thời gian (Mục 2.1–2.3). Lược đồ thích ứng phân cấp giảm độ dịch chuyển giữa các chủ thể ở ba mức: làm trắng Riemann cho đầu vào, chuẩn hóa AutoDIAL kèm hàm mất mát đối kháng và sai khác phân phối cho đặc trưng, và thích ứng tại thời điểm kiểm thử cho dự đoán (Mục 2.4–2.7). Mô hình được huấn luyện trên các lần thử có nhãn của chủ thể nguồn và các lần thử không nhãn của chủ thể đích (Giai đoạn 1), được thích ứng với các lần thử đánh giá không nhãn (Giai đoạn 2), rồi dùng để dự đoán (Giai đoạn 3).

2.1. Bộ mã hóa tích chập đa thang

Mỗi lần thử $X \in \mathbb{R}^{C\times T}$ (C điện cực, T mẫu) đi qua ba tích chập thời gian với kích thước nhân 20, 32 và 64 mẫu như trong TCFormer [9], tiếp theo là lọc không gian theo chiều sâu (depthwise), gộp (pooling), và tinh chỉnh theo nhóm xuống 16 kênh cho mỗi thang. Một cơ chế chú ý nhóm kênh có kết nối tắt gán một trọng số sigmoid cho mỗi thang, và bước gộp thứ hai tạo ra chuỗi đặc trưng cục bộ $H_c \in \mathbb{R}^{48\times L}$.

2.2. Bộ mã hóa không gian trạng thái chọn lọc hai chiều

Để nắm bắt các phụ thuộc trên toàn bộ lần thử, H_c đi qua năm khối không gian trạng thái chọn lọc [11, 12], mỗi khối điều khiển một phép hồi



Hình 1: Kiến trúc SSM-DAN. (a) Backbone SSM; kích thước tensor ghi theo kênh × thời gian, $\|$ là phép ghép theo kênh, $\oplus$ là phép cộng, và $\times N$ là $N = 5$ khối SSM chọn lọc với chiều quét xen kẽ. (b) Đầu thích ứng: chuẩn hóa AutoDIAL và bộ căn chỉnh có kết nối tắt dẫn vào ba nhánh song song (MMD, bộ phân loại, và GRL với bộ phân biệt miền); các hàm mất mát của chúng cùng MMD theo thời gian trên đầu ra TCN ở (a) tạo thành hàm mục tiêu Giai đoạn 1.

quy đường chéo với đầu vào đã chiếu u_t:

$$h_t = \exp(\Delta_t A) \odot h_{t-1} + \Delta_t B_t \odot u_t, \tag{1}$$

$$z_t = C_t^\top h_t + d \odot u_t, \tag{2}$$

trong đó $A = -\exp(A_{\log})$ là hệ số suy giảm ổn định được học, còn Δ_t, B_t và C_t phụ thuộc vào đầu vào, nhờ đó mỗi khối chọn bước thời gian cần giữ lại với chi phí tuyến tính. Các khối xen kẽ quét xuôi và quét ngược (Hình 1a), cho ngữ cảnh hai chiều mà không cần thêm khối. Số chiều trạng thái là tám, với dropout 0,4 và độ sâu ngẫu nhiên (stochastic depth).

2.3. Hợp nhất cục bộ–toàn cục và phân loại

Đầu ra không gian trạng thái được giảm xuống 16 kênh và ghép với chuỗi cục bộ 48 kênh H_c, để đầu phân loại thấy được cả bằng chứng cục bộ lẫn toàn cục. Hai khối mạng tích chập thời gian (TCN) theo nhóm có kết nối tắt, với độ dài nhân bốn và hệ số giãn một và hai, tinh chỉnh chuỗi 64 kênh thu được. Trung bình của bước thời gian cuối và giá trị trung bình theo thời gian tạo thành biểu diễn lần thử $q \in \mathbb{R}^{64}$, gồm bốn nhóm 16 kênh (ba thang tích chập và nhánh không gian trạng thái). Một bộ phân loại theo nhóm có ràng buộc chuẩn tạo một tập điểm lớp cho mỗi nhóm, rồi kết hợp bằng các trọng số softmax được học.

2.4. Căn chỉnh tín hiệu Riemann

Do cấu trúc hiệp phương sai EEG bị dịch chuyển giữa các chủ thể, căn chỉnh Riemann (RA) làm trắng các lần thử của mỗi chủ thể bằng căn bậc hai nghịch đảo của hiệp phương sai trung bình $\bar{R}$ của chủ thể đó, tức trung bình Riemann bất biến afin của các hiệp phương sai lần thử đã co rút OAS [27, 28]:

$$\widetilde{X} = \bar{R}^{-1/2} X. \tag{3}$$

Để tránh rò rỉ thông tin, $\bar{R}$ chỉ được ước lượng từ dữ liệu có sẵn trước khi đánh giá rồi áp dụng không đổi: từ các phiên huấn luyện cho các phiên kiểm định của mỗi chủ thể nguồn, và từ các phiên trước không nhãn $\mathcal{T}_a$ cho các phiên đánh giá $\mathcal{T}_e$ của chủ thể đích.

2.5. Lớp căn chỉnh miền tự động

Làm trắng Riemann căn chỉnh thống kê đầu vào nhưng không xử lý được các dịch chuyển phát sinh bên trong mạng. Vì vậy, theo AutoDIAL [25],

biểu diễn lần thử q được chuẩn hóa bằng một lớp học mức độ chuẩn hóa đặc trưng đích bằng thống kê của chính nó: đặc trưng nguồn dùng mô-men nguồn (μ_s, σ_s^2), còn đặc trưng đích dùng mô-men của hỗn hợp giữa phân phối nguồn và phân phối đích (μ_t, σ_t^2),

$$\mu_\alpha = \alpha\mu_t + (1-\alpha)\mu_s, \tag{4}$$
$$\sigma_\alpha^2 = \alpha\sigma_t^2 + (1-\alpha)\sigma_s^2 + \alpha(1-\alpha)(\mu_t - \mu_s)^2, \tag{5}$$

sao cho

$$\hat{q}^s = \gamma \odot \frac{q^s - \mu_s}{\sqrt{\sigma_s^2 + \epsilon}} + \beta, \qquad \hat{q}^t = \gamma \odot \frac{q^t - \mu_\alpha}{\sqrt{\sigma_\alpha^2 + \epsilon}} + \beta, \tag{6}$$

với các tham số afin dùng chung γ và β. Trọng số trộn $\alpha \in (0, 1)$, khởi tạo bằng 0,5 và được học riêng cho từng nhóm trong bốn nhóm đặc trưng, nội suy giữa thống kê nguồn ($\alpha \to 0$) và thống kê đích ($\alpha \to 1$). Các mô-men được tính theo từng mini-batch khi huấn luyện và được theo dõi bằng trung bình trượt (momentum 0,1), rồi được trộn với α đã học khi suy luận; các lần thử kiểm định nguồn luôn dùng thống kê nguồn.

2.6. Hàm mục tiêu huấn luyện

Một bộ căn chỉnh có kết nối tắt $64 \to 128 \to 64$ đặt trước bộ phân loại và các hàm mất mát căn chỉnh. Ngoài hàm entropy chéo trên dữ liệu nguồn $\mathcal{L}_{\text{cls}}$, Giai đoạn 1 dùng hàm mất mát miền với lớp đảo gradient $\mathcal{L}_{\text{adv}}$ [22], các hàm MK-MMD trên biểu diễn lần thử ($\mathcal{L}_{\text{mmd}}$) và trên chuỗi TCN ($\mathcal{L}_{\text{tmmd}}$) [20], và hàm cực đại hóa thông tin [29]

$$\mathcal{L}_{\text{IM}} = \frac{1}{N}\sum_{j=1}^{N} H(p_j) - H\left(\frac{1}{N}\sum_{j=1}^{N} p_j\right), \tag{7}$$

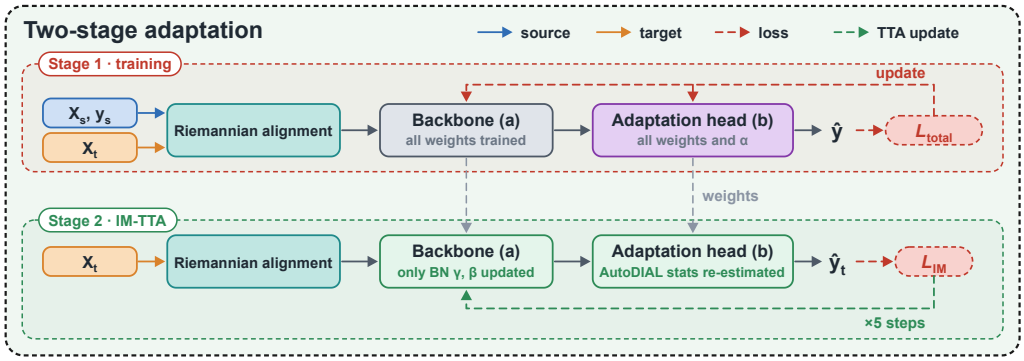
trong đó p_j là phân phối lớp dự đoán của lần thử thứ j trong N lần thử không nhãn và $H(\cdot)$ là entropy. Hàm mục tiêu là

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + 0.1\mathcal{L}_{\text{IM}}^t + \mathcal{L}_{\text{adv}} + 0.5\mathcal{L}_{\text{mmd}} + 0.1\mathcal{L}_{\text{tmmd}}. \tag{8}$$

trong đó $\mathcal{L}_{\text{IM}}^t$ được tính trên các lần thử đích thuộc $\mathcal{T}_a$. Các hàm mất mát căn chỉnh nhận đầu ra AutoDIAL với α cố định, nên α chỉ được học qua $\mathcal{L}_{\text{IM}}^t$.

2.7. Thích ứng tại thời điểm kiểm thử

Checkpoint có độ chính xác kiểm định nguồn cao nhất được thích ứng với các lần thử đánh giá không nhãn $\mathcal{T}_e$ bằng thích ứng tại thời điểm kiểm thử dựa trên cực đại hóa thông tin (IM-TTA): chỉ các hệ số tỉ lệ và độ dời của BatchNorm được cập nhật, giúp hạn chế quá khớp với tập đích nhỏ [30], bằng cách cực tiểu hóa Pt. (7) trên $\mathcal{T}_e$ trong năm lượt Adam (tốc độ học 10^{-4}). Sau đó, các mô-men đích của AutoDIAL được ước lượng lại trong một lượt trên cùng các lần thử đó, với α và mô-men nguồn cố định. Nhãn của $\mathcal{T}_e$ chỉ được dùng để chấm điểm. Hình 2 tóm tắt cả hai giai đoạn.



Hình 2: Thích ứng hai giai đoạn. Giai đoạn 1 huấn luyện backbone và đầu thích ứng (Hình 1), kể cả α, trên các lần thử nguồn có nhãn và đích không nhãn. Giai đoạn 2 (IM-TTA) bắt đầu từ các trọng số này, chỉ cập nhật tham số BatchNorm γ, β của backbone bằng $\mathcal{L}_{\text{IM}}$ trong năm bước, rồi ước lượng lại thống kê đích của AutoDIAL trước khi dự đoán.

3. Thiết lập thực nghiệm

3.1. Bộ dữ liệu

Ba bộ dữ liệu MI-EEG công khai, truy cập qua MOABB/Braindecode [31], được sử dụng (Bảng 1).

3.1.1. BCI Competition IV-2a

Chín người tham gia được ghi trong hai phiên vào các ngày khác nhau, mỗi phiên gồm 288 lần thử tưởng tượng tay trái, tay phải, hai chân và lưỡi, từ 22 điện cực EEG ở tần số 250 Hz (lọc thông dải 0,5–100 Hz, lọc chặn 50 Hz; ba kênh EOG không được sử dụng) [32].

Bảng 1: Tóm tắt các bộ dữ liệu MI-EEG (không tính kênh EOG).

Bộ dữ liệu	Số chủ thể	Số kênh	Số phiên	Các lớp
BCI IV-2a	9	22	2	tay trái, tay phải, chân, lưỡi
BCI IV-2b	9	3	5	tay trái, tay phải
Zhou2016	4	14	3	tay trái, tay phải, chân

3.1.2. BCI Competition IV-2b

Chín người tham gia thuận tay phải, lấy từ một nghiên cứu gồm mười người ($24,7 \pm 3,3$ tuổi) [33], thực hiện tưởng tượng tay trái so với tay phải, được ghi từ ba đạo trình lưỡng cực quanh C3, Cz và C4 ở 250 Hz (ba kênh EOG không được sử dụng). Các phiên 1–3 là phần hiệu chuẩn và các phiên 4–5 là phần đánh giá [32]; cách chia theo thời gian này được giữ nguyên, và bộ dữ liệu kiểm tra xem phương pháp còn hữu ích hay không khi chỉ có ba điện cực.

3.1.3. Zhou2016

Bốn người tham gia khỏe mạnh (22–28 tuổi), mỗi người được ghi trong ba phiên cách nhau từ vài ngày đến vài tháng [34]. Mỗi phiên có hai lượt ghi gồm 75 lần thử (25 lần mỗi lớp: tay trái, tay phải, chân) từ 14 điện cực ở 250 Hz; mỗi lần thử gồm 5 s gợi ý tưởng tượng, sau đó 4 s nghỉ.

3.2. Giao thức LOSO theo thời gian có thích ứng tại thời điểm kiểm thử

Mỗi lượt bỏ-một-chủ-thể (LOSO) giữ lại một chủ thể đích và dùng các chủ thể còn lại làm nguồn có nhãn, với cách chia phiên trong Bảng 2. Các phiên trước của chủ thể đích được dùng không kèm nhãn ở Giai đoạn 1; các phiên đánh giá bị loại khỏi huấn luyện và chọn mô hình, và EEG không nhãn của chúng chỉ được IM-TTA dùng trước khi chấm điểm.

Như vậy có chín lượt cho BCI IV-2a và IV-2b, bốn lượt cho Zhou2016, với siêu tham số giống nhau ở mọi lượt; checkpoint có độ chính xác kiểm định nguồn cao nhất được sử dụng. Với Zhou2016, điểm đích trên tất cả các phiên được báo cáo như một chỉ số chẩn đoán phụ.

3.3. Tiền xử lý và tăng cường dữ liệu

Các kênh EEG được lấy mẫu lại về 250 Hz và đổi sang microvolt. BCI IV-2a dùng toàn bộ cửa sổ sự kiện của MOABB và BCI IV-2b bỏ 0,5 s cuối,

Bảng 2: Phân bổ phiên theo thời gian trong mỗi lượt LOSO. Nhãn của phiên đánh giá chỉ được dùng để chấm điểm.

Bộ dữ liệu	Chủ thể nguồn (có nhãn)		Chủ thể đích	
	Huấn luyện	Kiểm định	UDA Giai đoạn 1 (không nhãn)	IM-TTA + đánh giá (ẩn nhãn)
BCI IV-2a	phiên 1	phiên 2	phiên 1	phiên 2
BCI IV-2b	phiên 1–3	phiên 4–5	phiên 1–3	phiên 4–5
Zhou2016	phiên 1–2	phiên 3	phiên 1–2	phiên 3

cả hai không lọc; Zhou2016 được lọc thông dải 8–30 Hz và cắt đoạn 0,5–5,0 s sau khi xuất hiện gợi ý.

Thống kê chuẩn hóa z-score được khớp trên phần huấn luyện nguồn. Với BCI IV-2a và IV-2b, các mini-batch nguồn có nhãn được nhân đôi bằng phép tăng cường phân đoạn và tái tổ hợp (S&R) [2] mà TCFormer sử dụng [9], ghép lại các mảnh tám đoạn từ các lần thử cùng lớp; Zhou2016 không dùng tăng cường.

3.4. Chi tiết cài đặt

Mọi thí nghiệm chạy trên Kaggle notebook với một GPU NVIDIA Tesla T4 (16 GB). BCI IV-2a và IV-2b dùng kích thước batch 48, tối đa 125 epoch, và Adam (tốc độ học 9×10^{-4}, $\beta_1 = 0,5$, suy giảm trọng số 10^{-3}); Zhou2016 dùng kích thước batch 32, 100 epoch, tốc độ học 10^{-3} và suy giảm trọng số 10^{-4}. Ba epoch khởi động tuyến tính được theo sau bởi suy giảm cosin. Hạt giống ngẫu nhiên (0), cách chia dữ liệu và khởi tạo là chung cho mọi phương pháp và biến thể, nên mỗi phép so sánh chỉ khác nhau ở thành phần được đánh giá.

3.5. Các phương pháp so sánh

Các phương pháp cơ sở được nhóm theo mức truy cập dữ liệu đích: chỉ dùng nguồn gồm EEG Conformer [7], ATCNet [8], TCFormer [9], EEGEncoder [35] và SATrans-Net [36]; dựa trên UDA là RMETNet [21]; và thích ứng tại thời điểm kiểm thử gồm T-TIME [37] và BFT [38]. Mỗi phương pháp được so sánh với biến thể SSM-DAN có cùng mức truy cập dữ liệu đích. Tất cả các phương pháp được huấn luyện lại từ mã nguồn công bố với cùng các lượt LOSO, cách chia theo thời gian, tiền xử lý, hạt giống ngẫu nhiên

và cách chọn checkpoint chỉ dựa trên nguồn; nhãn đánh giá không bao giờ tham gia huấn luyện hay chọn mô hình. Tối ưu hóa riêng của từng mô hình theo khuyến nghị gốc. Kết quả công bố theo các giao thức khác được báo cáo riêng ở Mục 4.5. Để ổn định số, hiệp phương sai của RMETNet trên Zhou2016 được cộng thêm một hệ số ridge bằng 10^{-3} lần trị riêng trung bình.

3.6. Thước đo đánh giá và cách báo cáo

Độ chính xác và κ của Cohen được báo cáo dưới dạng trung bình ± độ lệch chuẩn trên các chủ thể đích. Tốc độ truyền thông tin (ITR) [39] biểu diễn độ chính xác P trên N lớp là

$$\mathrm{ITR} = \frac{60}{T}\left[\log_2 N + P\log_2 P + (1-P)\log_2\frac{1-P}{N-1}\right] \text{ bit/phút}, \qquad (9)$$

trong đó T là cửa sổ giải mã (4 s cho BCI IV-2a/2b; 4,5 s cho Zhou2016); các giá trị bằng hoặc thấp hơn mức ngẫu nhiên được đặt bằng không trước khi lấy trung bình. Độ nhạy (recall) theo lớp và macro-F1 đánh giá sự cân bằng giữa các lớp. Hiệu độ chính xác theo cặp được kiểm định bằng phép Wilcoxon hai phía chính xác, có hiệu chỉnh Holm trong mỗi nhóm truy cập dữ liệu đích (Mục 3.5); $p_{\mathrm{Holm}} < 0,05$ biểu thị có ý nghĩa thống kê. Hiệu năng tính toán được báo cáo bằng số tham số, thời gian huấn luyện Giai đoạn 1 và độ trễ CPU với batch bằng một.

4. Kết quả

Các Bảng 3–5 báo cáo kết quả LOSO theo thời gian cho từng chủ thể. Độ lệch chuẩn mô tả sự biến thiên giữa các chủ thể đích, không phải giữa các lần lặp với hạt giống khác nhau.

4.1. BCI Competition IV-2a

Bảng 3 báo cáo kết quả bốn lớp cho chín chủ thể đích của BCI IV-2a.

SSM-DAN đạt độ chính xác và κ cao nhất, và vượt trội có ý nghĩa thống kê so với mọi phương pháp cơ sở chỉ dùng nguồn cũng như biến thể chỉ dùng nguồn của chính nó trên cả chín chủ thể đích ($p_{\mathrm{Holm}} = 0,0312$). IM-TTA cải thiện mọi chủ thể đích so với SSM-DAN (UDA Giai đoạn 1). Trong nhóm UDA, SSM-DAN (UDA Giai đoạn 1) vượt có ý nghĩa so với RMETNet ($60,11 \pm 11,05\%$) trên cả chín chủ thể đích. Trong nhóm thích ứng tại thời điểm kiểm thử, SSM-DAN (IM-TTA) vượt có ý nghĩa so với BFT trên cả chín chủ thể đích và vượt T-TIME trên bảy chủ thể, dù khác biệt sau không có ý nghĩa thống kê.

Bảng 3: Độ chính xác LOSO theo từng chủ thể (%), kèm κ của Cohen trung bình và tốc độ truyền thông tin trung bình (ITR, Pt. (9)), trên BCI IV-2a (bốn lớp). p: kiểm định hạng có dấu Wilcoxon chính xác hai phía so với mô hình SSM-DAN cùng nhóm (Mục 3.5); p_{Holm}: p hiệu chỉnh theo thủ tục Holm–Bonferroni trong từng nhóm (Mục 3.6). –: mô hình tham chiếu.

Phương pháp	Độ chính xác theo chủ thể đích (%)									Trung bình ± ĐLC			p	p_{Holm}
	S1	S2	S3	S4	S5	S6	S7	S8	S9	Đ.c.x. (%)	κ	ITR (bit/phút)		
Huấn luyện chỉ dùng nguồn														
Conformer [7]	58.68	43.06	78.82	43.06	44.44	41.67	72.92	65.28	49.31	55.25 ± 13.39	0.403 ± 0.179	5.29 ± 4.58	0.0039	0.0312
ATCNet [8]	69.44	40.97	76.74	50.35	43.40	42.01	61.81	70.49	57.99	57.02 ± 12.74	0.427 ± 0.170	5.73 ± 4.19	0.0039	0.0312
TCFormer [9]	65.28	49.65	79.86	54.86	61.81	38.89	71.88	66.67	58.33	60.80 ± 11.49	0.477 ± 0.153	6.80 ± 4.02	0.0039	0.0312
EEGEncoder [35]	64.24	49.31	78.82	46.18	54.86	40.97	74.31	65.97	47.92	58.06 ± 12.55	0.441 ± 0.167	6.04 ± 4.43	0.0039	0.0312
SATrans-Net [36]	68.06	47.92	73.96	53.47	61.11	45.14	73.61	71.53	63.19	62.00 ± 10.34	0.493 ± 0.138	7.09 ± 3.62	0.0039	0.0312
SSM-DAN (chỉ nguồn)	68.06	51.04	86.46	61.11	64.24	39.58	72.92	73.61	62.15	64.35 ± 12.77	0.525 ± 0.170	8.22 ± 4.97	0.0039	0.0312
Thích ứng miền không giám sát														
RMETNet [21]	67.01	39.24	77.78	55.90	49.65	52.78	63.54	66.67	68.40	60.11 ± 11.05	0.468 ± 0.147	6.52 ± 3.73	0.0039	0.0039
SSM-DAN (UDA Giai đoạn 1)	79.17	47.57	92.71	73.61	57.64	59.72	82.29	82.64	73.96	72.15 ± 13.58	0.629 ± 0.181	11.60 ± 6.31	0.0039	0.0312
Thích ứng tại thời điểm kiểm thử														
T-TIME [37]	67.01	53.47	78.47	64.58	68.75	49.65	79.51	69.44	65.28	66.24 ± 9.34	0.550 ± 0.125	8.56 ± 3.73	0.0742	0.0742
BFT [38]	64.24	44.44	76.74	65.62	61.81	51.39	73.61	70.49	59.38	63.08 ± 9.77	0.508 ± 0.130	7.42 ± 3.51	0.0039	0.0078
SSM-DAN (IM-TTA)	77.43	47.92	88.19	66.32	64.24	61.81	79.86	82.99	73.61	71.37 ± 11.78	0.618 ± 0.157	10.98 ± 5.27	0.0039	0.0312
SSM-DAN	**79.51**	**52.43**	**93.40**	**73.96**	**69.44**	**65.97**	**88.89**	**86.11**	**75.35**	$\mathbf{76.12 \pm 11.96}$	$\mathbf{0.682 \pm 0.159}$	$\mathbf{13.30 \pm 6.15}$	–	–

4.2. BCI Competition IV-2b

Bảng 4 báo cáo kết quả hai lớp cho chín chủ thể đích của BCI IV-2b, vốn chỉ có ba đạo trình EEG lưỡng cực.

Bảng 4: Độ chính xác LOSO theo từng chủ thể (%), kèm κ của Cohen trung bình và tốc độ truyền thông tin trung bình (ITR, Pt. (9)), trên BCI IV-2b (hai lớp). p: kiểm định hạng có dấu Wilcoxon chính xác hai phía so với mô hình SSM-DAN cùng nhóm (Mục 3.5); p_{Holm}: p hiệu chỉnh theo thủ tục Holm–Bonferroni trong từng nhóm (Mục 3.6). –: mô hình tham chiếu.

Phương pháp	Độ chính xác theo chủ thể đích (%)									Trung bình ± ĐLC			p	p_{Holm}
	S1	S2	S3	S4	S5	S6	S7	S8	S9	Đ.c.x. (%)	κ	ITR (bit/phút)		
Huấn luyện chỉ dùng nguồn														
Conformer [7]	75.31	62.86	55.62	92.50	94.69	74.06	82.81	82.50	81.88	78.03 ± 12.02	0.561 ± 0.240	4.55 ± 3.51	0.0156	0.1094
ATCNet [8]	76.25	65.71	57.19	90.00	96.88	77.50	84.06	84.69	82.19	79.38 ± 11.40	0.588 ± 0.228	4.89 ± 3.58	0.0078	0.0625
TCFormer [9]	78.44	69.64	64.38	90.62	95.00	75.94	86.87	85.31	84.38	81.18 ± 9.37	0.624 ± 0.187	5.17 ± 3.16	0.0820	0.3281
EEGEncoder [35]	73.44	65.71	59.06	92.50	97.19	85.00	85.94	86.56	83.75	81.02 ± 11.76	0.620 ± 0.235	5.48 ± 3.81	0.0547	0.2734
SATrans-Net [36]	77.50	69.29	69.69	90.62	97.50	79.69	87.50	84.38	79.69	81.76 ± 8.78	0.635 ± 0.176	5.36 ± 3.45	0.2109	0.6094
SSM-DAN (chỉ nguồn)	77.81	68.57	63.13	89.38	96.56	73.44	84.69	86.25	85.00	80.54 ± 10.05	0.611 ± 0.201	5.07 ± 3.44	0.0156	0.1094
Thích ứng miền không giám sát														
RMETNet [21]	73.12	57.86	55.00	91.56	94.06	82.81	85.62	88.75	83.13	79.10 ± 13.39	0.582 ± 0.268	5.04 ± 3.54	0.0117	0.0117
SSM-DAN (UDA Giai đoạn 1)	78.44	70.71	63.44	90.31	97.81	83.75	89.69	95.63	85.94	83.97 ± 10.71	0.679 ± 0.214	$\mathbf{6.42 \pm 3.98}$	1.0000	1.0000
Thích ứng tại thời điểm kiểm thử														
T-TIME [37]	59.69	65.36	85.31	93.75	97.19	85.00	74.69	91.25	59.06	79.03 ± 13.94	0.581 ± 0.279	5.24 ± 4.39	0.3125	0.3125
BFT [38]	75.00	65.00	59.69	93.44	94.69	79.06	88.12	94.37	81.25	81.18 ± 12.12	0.624 ± 0.242	5.60 ± 3.96	0.0078	0.0156
SSM-DAN (IM-TTA)	77.81	68.57	66.25	93.75	96.25	81.88	89.69	94.69	81.25	83.35 ± 10.50	0.667 ± 0.210	6.15 ± 3.92	0.2031	0.6094
SSM-DAN	77.81	69.29	65.94	90.00	97.19	84.69	91.56	95.31	85.00	$\mathbf{84.09 \pm 10.42}$	$\mathbf{0.682 \pm 0.208}$	$\mathbf{6.42 \pm 3.90}$	–	–

SSM-DAN một lần nữa đạt độ chính xác trung bình cao nhất. Nó vượt

biến thể chỉ dùng nguồn của chính nó trên cả bảy chủ thể đích có độ chính xác không bằng nhau, vượt ATCNet trên cả tám, và vượt EEG Conformer trên tám trong chín chủ thể ($p = 0,0078$–$0,0156$), nhưng các khác biệt này không còn ý nghĩa sau hiệu chỉnh Holm ($p_{\text{Holm}} = 0,0625$–$0,1094$); lợi thế của nó so với TCFormer, EEGEncoder, SATrans-Net và SSM-DAN (UDA Giai đoạn 1) nhỏ và không có ý nghĩa, với IM-TTA chỉ giúp ích trên ba chủ thể đích. Trong các nhóm tương ứng, SSM-DAN (UDA Giai đoạn 1) vượt có ý nghĩa so với RMETNet và SSM-DAN (IM-TTA) vượt có ý nghĩa so với BFT; SSM-DAN (IM-TTA) cũng vượt T-TIME ($79,03 \pm 13,94\%$) về trung bình, nhưng không có ý nghĩa, do T-TIME dao động mạnh hơn nhiều giữa các chủ thể đích.

4.3. Zhou2016

Bảng 5 báo cáo kết quả ba lớp trên phiên đích thứ 3 của Zhou2016. Với bốn lượt, giá trị p Wilcoxon hai phía nhỏ nhất có thể đạt là 0,125, nên không khác biệt nào có thể có ý nghĩa thống kê.

Bảng 5: Độ chính xác LOSO theo từng chủ thể (%), kèm κ của Cohen trung bình và tốc độ truyền thông tin trung bình (ITR, Pt. (9)), trên phiên 3 của Zhou2016 (ba lớp). In đậm: tốt nhất mỗi cột. p: kiểm định hạng có dấu Wilcoxon chính xác hai phía so với mô hình SSM-DAN cùng nhóm (Mục 3.5); p_{Holm}: p hiệu chỉnh theo thủ tục Holm–Bonferroni trong từng nhóm (Mục 3.6). –: mô hình tham chiếu.

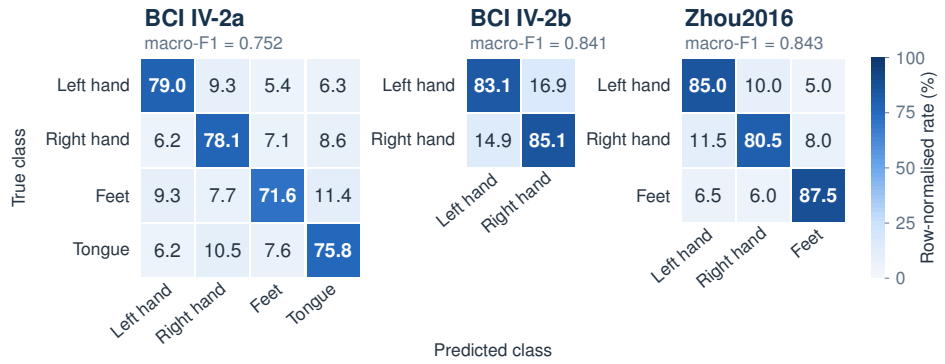
Phương pháp	Độ chính xác theo chủ thể đích (%)				Trung bình ± ĐLC			p	p_{Holm}
	S1	S2	S3	S4	Đ.c.x. (%)	κ	ITR (bit/phút)		
Huấn luyện chỉ dùng nguồn									
Conformer [7]	76.00	79.33	70.67	82.67	77.17 ± 4.43	0.657 ± 0.066	7.86 ± 1.86	0.1250	1.0000
ATCNet [8]	72.00	82.67	76.67	74.67	76.50 ± 3.93	0.648 ± 0.059	7.60 ± 1.70	0.1250	1.0000
TCFormer [9]	68.00	78.67	66.67	80.67	73.50 ± 6.22	0.603 ± 0.093	6.67 ± 2.39	0.1250	1.0000
EEGEncoder [35]	62.00	84.00	74.67	76.67	74.33 ± 7.92	0.615 ± 0.119	7.07 ± 2.98	0.2500	1.0000
SATrans-Net [36]	81.33	80.00	67.33	70.00	74.67 ± 6.09	0.620 ± 0.091	7.06 ± 2.40	0.1250	1.0000
SSM-DAN (chỉ nguồn)	72.00	78.67	71.33	78.67	75.17 ± 3.51	0.627 ± 0.053	7.10 ± 1.41	0.1250	1.0000
Thích ứng miền không giám sát									
RMETNet [21]	70.00	**89.33**	80.67	84.67	81.17 ± 7.14	0.718 ± 0.107	9.63 ± 3.29	0.8750	1.0000
SSM-DAN (UDA Giai đoạn 1)	79.33	84.67	**87.33**	78.00	82.33 ± 3.82	0.735 ± 0.057	9.90 ± 1.92	0.6250	1.0000
Thích ứng tại thời điểm kiểm thử									
T-TIME [37]	**88.67**	84.00	81.33	**86.00**	$\mathbf{85.00 \pm 2.69}$	$\mathbf{0.775 \pm 0.040}$	$\mathbf{11.06 \pm 1.46}$	0.5000	0.8750
BFT [38]	84.00	86.67	76.00	84.67	82.83 ± 4.07	0.743 ± 0.061	10.13 ± 1.94	0.8750	1.0000
SSM-DAN (IM-TTA)	79.33	84.00	83.33	83.33	82.50 ± 1.85	0.738 ± 0.028	9.90 ± 0.89	0.2500	1.0000
SSM-DAN	84.00	83.33	84.67	85.33	84.33 ± 0.75	0.765 ± 0.011	10.70 ± 0.39	–	–

SSM-DAN có hiệu năng ổn định nhất giữa các chủ thể đích và vượt mọi phương pháp cơ sở chỉ dùng nguồn cũng như biến thể chỉ dùng nguồn của

nó trên cả bốn chủ thể đích, ngoại trừ EEGEncoder, mà nó vượt trên ba. Trong nhóm UDA, RMETNet thấp hơn một chút so với mô hình tham chiếu SSM-DAN (UDA Giai đoạn 1) về trung bình và dao động mạnh hơn nhiều giữa các chủ thể, dù đạt độ chính xác cao nhất trên chủ thể đích 2. Trong nhóm thích ứng tại thời điểm kiểm thử, T-TIME đạt độ chính xác trung bình cao nhất trên bộ dữ liệu này, cao hơn cả mô hình tham chiếu SSM-DAN (IM-TTA) lẫn SSM-DAN đầy đủ, trong khi BFT ngang bằng mô hình tham chiếu. SSM-DAN cũng vẫn cao hơn TCFormer ở điểm phụ gộp trên cả ba phiên đích.

4.4. Tốc độ truyền thông tin và hiệu năng theo lớp

Về mặt thực tế, mức tăng độ chính xác của SSM-DAN chuyển thành giao tiếp nhanh hơn. Trên BCI IV-2a, thích ứng làm ITR tăng khoảng 60% so với biến thể chỉ dùng nguồn (13, 3 so với 8, 2 bit/phút; Bảng 3), nên một người dùng mới có thể đưa ra nhiều lệnh hơn đáng kể mỗi phút mà không cần hiệu chuẩn có nhãn. Trên BCI IV-2b và Zhou2016, các phương pháp thích ứng hoạt động trong khoảng tương tự nhau, phản ánh kết quả độ chính xác.



Hình 3: Ma trận nhầm lẫn trung bình của SSM-DAN trên các phiên đánh giá của BCI IV-2a (trái), BCI IV-2b (giữa) và Zhou2016 (phải). Ma trận của mỗi chủ thể được chuẩn hóa theo số lần thử của từng lớp thật rồi lấy trung bình trên các chủ thể đích, nên đường chéo cho độ nhạy trung bình của mỗi lớp; điểm F1 trung bình macro được ghi dưới tên mỗi bộ dữ liệu.

Hình 3 cho thấy các mức tăng này trải đều trên các lớp chứ không đạt được bằng cách ưu tiên một lớp dễ: macro-F1 bám sát độ chính xác trên mọi bộ dữ liệu và không lớp nào bị bỏ qua một cách có hệ thống. Điều này quan trọng với thích ứng tại thời điểm kiểm thử, vì hàm mục tiêu entropy có thể

khiến dự đoán sụp về một vài lớp. Các lỗi còn lại cũng hợp lý về mặt sinh lý: trên BCI IV-2a, tưởng tượng chân bị nhầm nhiều nhất với tưởng tượng lưỡi, hai tác vụ được biểu diễn gần đường giữa của vỏ não cảm giác–vận động, trong khi các lớp tay lệch bên được nhận dạng tốt nhất.

4.5. So sánh với các kết quả đã công bố

Bảng 6 đối chiếu độ chính xác liên chủ thể được báo cáo trong các bài báo gốc với kết quả chạy lại trong nghiên cứu này. Các giá trị đã công bố không so sánh trực tiếp được, vì các giao thức khác nhau ở bốn điểm. (i) *Tác vụ*: các bài T-TIME và BFT báo cáo MI hai lớp tay trái so với tay phải, trong khi BCI IV-2a và Zhou2016 ở đây được đánh giá với bốn và ba lớp. (ii) *Dịch chuyển phiên và dữ liệu đích*: một số giao thức huấn luyện và kiểm thử trong cùng một phiên ghi, và bài EEGEncoder hoàn toàn không báo cáo kết quả liên chủ thể, con số đa chủ thể của họ thu được khi tập huấn luyện chứa cả phiên đầu của chính các chủ thể kiểm thử; ở đây mọi chủ thể đích đều chưa được thấy khi huấn luyện và được chấm điểm trên một phiên sau, ghi vào ngày khác. (iii) *Chọn mô hình*: các script công bố của SATrans-Net và RMETNet báo cáo độ chính xác theo epoch cao nhất, hoặc trung bình năm giá trị cao nhất, trên chủ thể bị giữ lại, tức nhãn đánh giá được dùng để chọn epoch; ở đây checkpoint chỉ được chọn dựa trên dữ liệu nguồn. (iv) *Truy cập chuyển nạp (transductive)*: RMETNet dùng chính các lần thử đánh giá bị giữ lại làm miền đích cho hàm MMD và căn chỉnh Riemann, trong khi ở đây thích ứng miền chỉ thấy các phiên đích trước đó, không nhãn. Mỗi điểm (ii)–(iv) làm giao thức dễ hơn hoặc ước lượng lạc quan hơn, điều này phần lớn giải thích vì sao hầu hết kết quả chạy lại thấp hơn trên BCI IV-2a. Khi cách chia khớp với của chúng tôi, chênh lệch nhỏ: benchmark của TCFormer [9] dùng cùng cách chia phiên và chỉ khác ở việc lấy trung bình mô hình epoch cuối trên năm hạt giống và tiền xử lý riêng theo mô hình, và kết quả chạy lại của TCFormer và ATCNet nằm trong phạm vi ba điểm so với benchmark đó trên cả hai bộ BCI, còn EEG Conformer ở đây cao hơn. Trên BCI IV-2b, nơi dịch chuyển giữa phiên hiệu chuẩn và phiên đánh giá nhỏ hơn, kết quả chạy lại đạt hoặc vượt một số giá trị đã công bố (ví dụ SATrans-Net, 81,76 so với 79,64%).

4.6. Nghiên cứu loại bỏ thành phần

Bảng 7 tuân theo giao thức chính theo thời gian. Biến thể không có thích ứng miền loại bỏ mọi thành phần thích ứng miền ở Giai đoạn 1 (AutoDIAL, cực đại hóa thông tin trên đích, hàm mất mát đối kháng và cả hai hàm

Bảng 6: Độ chính xác liên chủ thể (%) đã công bố của các phương pháp cơ sở so với kết quả chạy lại theo giao thức của nghiên cứu này (Bảng 2). –: không báo cáo; các thiết lập (a)–(e) được nêu dưới bảng.

		Đã công bố			Nghiên cứu này (LOSO theo thời gian)		
Phương pháp	Thiết lập	BCI IV-2a	BCI IV-2b	Zhou2016	BCI IV-2a	BCI IV-2b	Zhou2016
EEG Conformer [7]	(a) [9]	45.59	75.25	–	55.25	78.03	77.17
ATCNet [8]	(a) [9]	59.66	80.94	–	57.02	79.38	76.50
TCFormer [9]	(a)	63.00	81.34	–	60.80	81.18	73.50
EEGEncoder [35]	(b)	–	–	–	58.06	81.02	74.33
SATrans-Net [36]	(c)	68.13	79.64	–	62.00	81.76	74.67
RMETNet [21]	(d)	71.39	80.93	–	60.11	79.10	81.17
T-TIME [37]	(e)	79.30†	–	–	66.24	79.03	85.00
BFT [38]	(e)	77.47†	–	84.38†	63.08	81.18	82.83

(a) Cùng cách chia phiên như ở đây, mô hình epoch cuối lấy trung bình trên năm hạt giống, tiền xử lý riêng theo mô hình. (b) Không có kết quả liên chủ thể; con số 74,48% trên BCI IV-2a huấn luyện trên phiên 1 của mọi chủ thể, kể cả chủ thể kiểm thử. (c) LOSO không nêu cách chia phiên, lấy độ chính xác kiểm thử cao nhất theo epoch. (d) Một phiên cho mỗi chủ thể, chủ thể bị giữ lại được dùng làm đích cho MMD/RA, trung bình năm epoch tốt nhất. (e) Thích ứng tại thời điểm kiểm thử trực tuyến chỉ trên phiên 1. †Tác vụ hai lớp (tay trái so với tay phải).

MMD) nhưng giữ lại căn chỉnh Riemann và IM-TTA; ngoài ra, mọi biến thể dùng cùng các lượt và cùng quy tắc chọn checkpoint.

OpenBMI (Lee2019_MI) [40] được bổ sung như một tập chủ thể lớn hơn cho nghiên cứu loại bỏ thành phần. Bộ dữ liệu gồm 54 chủ thể, ghi bằng 62 kênh EEG trong hai phiên vào hai ngày khác nhau; mỗi phiên có một lượt ghi ngoại tuyến gồm 100 lần thử tưởng tượng tay trái hoặc tay phải. Tín hiệu được lọc thông dải 4–38 Hz, tham chiếu lại theo trung bình chung, hạ mẫu xuống 100 Hz và cắt trong khoảng 0–4 s sau tín hiệu gợi ý; không dùng tăng cường S&R. Nhờ có hai phiên, OpenBMI dùng được cùng giao thức theo thời gian như các bộ dữ liệu còn lại: trong mỗi lượt của 54 lượt LOSO, 53 chủ thể nguồn cung cấp các lần thử có nhãn của phiên 1 để huấn luyện và của phiên 2 để chọn checkpoint, còn phiên 1 không nhãn của chủ thể đích được dùng ở Giai đoạn 1 và phiên 2 dùng cho IM-TTA và đánh giá. RA được khớp trên phiên 1 của từng chủ thể, và mọi biến thể dùng thiết lập tối ưu của BCI IV-2a. Do mỗi phiên đánh giá có 100 lần thử cân bằng hai lớp, $\kappa = 2P - 1$ với độ chính xác P. Với 54 cặp chủ thể đích, kiểm định Wilcoxon trên OpenBMI dùng xấp xỉ chuẩn thay cho phép liệt kê chính xác, kèm hiệu chỉnh Holm trên bốn phép so sánh loại bỏ thành phần.

Trên BCI IV-2a, việc loại bỏ căn chỉnh Riemann, thích ứng miền Giai đoạn 1, hoặc thích ứng tại thời điểm kiểm thử đều làm giảm độ chính xác

Bảng 7: Kết quả loại bỏ thành phần: trung bình ± độ lệch chuẩn của độ chính xác (%) và κ của Cohen trên các chủ thể đích. Biến thể tốt nhất của mỗi bộ dữ liệu được in đậm. Cột cuối thay tham chiếu RA cố định của SSM-DAN bằng tham chiếu theo từng phiên (Mục 4.7). [a]53 trong 54 chủ thể đích của OpenBMI.

Bộ dữ liệu	Thước đo	SSM-DAN	Chỉ huấn luyện trên nguồn	Không có căn chỉnh Riemann	Không có thích ứng miền	Không có thích ứng tại thời điểm kiểm thử	Tham chiếu RA theo từng phiên
BCI IV-2a	Đ.c.x.	76.12 ± 11.96	64.35 ± 12.77	70.29 ± 11.60	71.37 ± 11.78	72.15 ± 13.58	$\mathbf{77.74 \pm 11.72}$
	κ	0.682 ± 0.159	0.525 ± 0.170	0.604 ± 0.155	0.618 ± 0.157	0.629 ± 0.181	$\mathbf{0.703 \pm 0.156}$
BCI IV-2b	Đ.c.x.	84.09 ± 10.42	80.54 ± 10.05	83.58 ± 10.46	83.35 ± 10.50	83.97 ± 10.71	$\mathbf{84.10 \pm 10.23}$
	κ	$\mathbf{0.682 \pm 0.208}$	0.611 ± 0.201	0.672 ± 0.209	0.667 ± 0.210	0.679 ± 0.214	$\mathbf{0.682 \pm 0.205}$
Zhou2016	Đ.c.x.	84.33 ± 0.75	75.17 ± 3.51	84.00 ± 3.16	82.50 ± 1.85	82.33 ± 3.82	$\mathbf{85.33 \pm 2.05}$
	κ	0.765 ± 0.011	0.627 ± 0.053	0.760 ± 0.047	0.738 ± 0.028	0.735 ± 0.057	$\mathbf{0.780 \pm 0.031}$
OpenBMI	Đ.c.x.	80.61 ± 10.26	79.92 ± 11.04^a	83.50 ± 9.43	79.85 ± 10.02	76.65 ± 12.19	$\mathbf{84.00 \pm 9.56}$
	κ	0.612 ± 0.205	0.598 ± 0.221^a	0.670 ± 0.189	0.597 ± 0.200	0.533 ± 0.244	$\mathbf{0.680 \pm 0.191}$

có ý nghĩa thống kê. Trên BCI IV-2b và Zhou2016, mô hình đầy đủ vẫn là biến thể tốt nhất, nhưng mức chênh nhỏ và không có ý nghĩa. Do đó, đóng góp của từng thành phần phụ thuộc vào bộ dữ liệu. Trên OpenBMI, IM-TTA tăng độ chính xác thêm 3,96 điểm (cao hơn ở 38 trong 54 chủ thể đích, $p_{\text{Holm}} < 0{,}001$), trong khi mức tăng so với biến thể không có thích ứng miền (0,76 điểm) và so với mô hình chỉ huấn luyện trên nguồn (0,51 điểm) không có ý nghĩa ($p_{\text{Holm}} = 0{,}68$ và 0,72). Ngược lại, loại bỏ RA làm độ chính xác tăng 2,89 điểm (cao hơn ở 33 trong 54 chủ thể đích, $p_{\text{Holm}} = 0{,}002$): với tham chiếu cố định trên phiên 1, RA làm giảm độ chính xác trên bộ dữ liệu này. Mục 4.7 phân tích hiện tượng này.

4.7. Tham chiếu RA theo từng phiên

Tham chiếu cố định giả định rằng hiệp phương sai trung bình của một chủ thể ổn định giữa các phiên. Trên OpenBMI, giả định này không đúng: sau RA theo phiên 1, trung vị năng lượng lần thử của phiên 2 bằng 1,55 lần phiên 1 tính trên các chủ thể, và hơn hai lần ở 20 trong 54 chủ thể, so với 1,08–1,39 lần trên BCI IV-2a. Vì vậy, SSM-DAN được chạy lại với tham chiếu theo từng phiên: mỗi phiên của mỗi chủ thể, kể cả phiên đánh giá của chủ thể đích, được làm trắng bằng trung bình Riemann của chính các lần thử không nhãn trong phiên đó. Tham chiếu của phiên đánh giá dùng đúng các lần thử đánh giá không nhãn mà IM-TTA vốn đã truy cập, nên mức truy cập dữ liệu đích không thay đổi; giống IM-TTA, nó cần các lần thử này theo

lô. Mọi thiết lập khác giữ nguyên như các thí nghiệm chính; kết quả nằm ở cột cuối của Bảng 7.

Trên OpenBMI, tham chiếu theo từng phiên tăng 3,39 điểm khi có IM-TTA (84,00% so với 80,61%; cao hơn ở 43 trong 54 chủ thể đích, $p < 0{,}001$) và 7,24 điểm khi không có IM-TTA (83,89% so với 76,65%; 45 trong 54, $p < 0{,}001$), trong khi mức đóng góp của IM-TTA giảm từ 3,96 xuống 0,11 điểm ($p = 0{,}50$); như vậy phần lớn lợi ích của IM-TTA khi dùng tham chiếu cố định là bù cho độ lệch năng lượng giữa các phiên. Với tham chiếu theo từng phiên, SSM-DAN cũng vượt biến thể không có RA (84,00% so với 83,50%), dù không có ý nghĩa ($p = 0{,}61$). Trên BCI IV-2a, độ chính xác tăng 1,62 điểm khi có IM-TTA (8 trong 9 chủ thể đích, p chính xác $= 0{,}023$), và IM-TTA vẫn đóng góp thêm 2,89 điểm (từ 74,85% lên 77,74%; 8 trong 9, $p = 0{,}008$). Trên BCI IV-2b, hai loại tham chiếu cho độ chính xác như nhau (84,10% so với 84,09%; cao hơn ở 3 chủ thể đích, thấp hơn ở 5, $p = 0{,}97$). Trên Zhou2016, tham chiếu theo từng phiên tăng 1,00 điểm (85,33% so với 84,33%; cao hơn ở 3 trong 4 chủ thể đích, p chính xác $= 0{,}38$), và IM-TTA đóng góp thêm 2,83 điểm (từ 82,50% lên 85,33%; 4 trong 4, $p = 0{,}125$, giá trị nhỏ nhất có thể đạt với bốn chủ thể đích). Do biến thể này được khảo sát sau các thí nghiệm chính, các kiểm định trên không hiệu chỉnh Holm và chỉ đóng vai trò bằng chứng bổ trợ; mọi kết quả khác dùng tham chiếu cố định.

4.8. Hiệu năng tính toán

Bảng 8 báo cáo số tham số huấn luyện được, thời gian huấn luyện Giai đoạn 1 và thời gian phản hồi trên CPU. Biến thể chỉ dùng nguồn nhỏ hơn vì không có lớp AutoDIAL, bộ căn chỉnh và bộ phân biệt miền; RA và IM-TTA không làm thay đổi số tham số.

Thích ứng Giai đoạn 1 chiếm phần lớn thời gian huấn luyện tăng thêm của SSM-DAN so với biến thể chỉ dùng nguồn (gần gấp đôi trên Zhou2016), trong khi IM-TTA chỉ thêm rất ít. SSM-DAN có số tham số tương đương ATCNet và TCFormer, thấp hơn nhiều so với EEG Conformer, còn T-TIME và BFT là các phương pháp nhỏ và nhanh nhất.

Bảng 8: Chi phí tính toán: số tham số huấn luyện được, thời gian huấn luyện Giai đoạn 1 trung bình mỗi lượt, và thời gian phản hồi CPU cho một lần thử. Các biến thể SSM-DAN như ở Mục 3.5.

	BCI IV-2a			BCI IV-2b			Zhou2016		
Phương pháp	Tham số (K)	Huấn luyện (phút)	CPU (ms)	Tham số (K)	Huấn luyện (phút)	CPU (ms)	Tham số (K)	Huấn luyện (phút)	CPU (ms)
Huấn luyện chỉ dùng nguồn									
Conformer	789.6	11.14	11.45	759.1	4.93	9.34	858.7	1.53	10.34
ATCNet	113.7	48.58	13.33	112.8	60.19	11.35	113.3	8.09	11.91
TCFormer	127.2	38.37	14.96	123.4	31.04	11.17	125.6	5.89	15.97
EEGEncoder	197.2	13.49	26.51	196.2	14.98	26.88	196.8	3.64	25.68
SATrans-Net	155.6	10.19	12.78	153.7	4.99	11.10	155.0	1.32	11.38
SSM-DAN (chỉ nguồn)	98.4	47.01	25.08	94.6	36.10	13.68	96.8	6.29	13.36
Thích ứng miền không giám sát									
RMETNet	193.8	45.88	11.15	159.1	21.96	4.90	306.6	23.74	7.19
SSM-DAN (UDA Giai đoạn 1)	132.0	58.45	18.44	128.2	48.08	13.35	130.4	11.42	14.65
Thích ứng tại thời điểm kiểm thử									
T-TIME	9.5	5.85	7.71	6.3	3.07	5.08	8.4	1.34	6.72
BFT	40.6	1.47	3.08	39.9	0.96	2.61	51.0	0.36	2.84
SSM-DAN (IM-TTA)	131.9	40.73	22.12	128.1	33.21	14.25	130.3	6.46	18.41
SSM-DAN (không RA)	132.0	58.41	21.63	128.2	47.95	13.33	130.4	11.66	18.88
SSM-DAN	**132.0**	**59.82**	**22.20**	**128.2**	**54.21**	**17.40**	**130.4**	**11.70**	**19.14**

5. Thảo luận

Lợi ích của từng thành phần thích ứng phụ thuộc vào bộ dữ liệu: rõ rệt trên BCI IV-2a nhưng nhỏ và không có ý nghĩa trên BCI IV-2b và Zhou2016, nơi cần các thí nghiệm lặp với nhiều hạt giống để xác nhận khác biệt. Tập OpenBMI lớn hơn xác nhận lợi ích của IM-TTA, nhưng cho thấy tham chiếu RA cố định trên một phiên trước có thể làm giảm độ chính xác khi năng lượng tín hiệu thay đổi giữa các phiên. Ước lượng lại tham chiếu trên từng phiên loại bỏ được mức giảm này và giải thích phần lớn lợi ích của IM-TTA, gợi ý rằng một phần lớn độ dịch chuyển giữa các phiên mà thích ứng tại thời điểm kiểm thử xử lý là sự thay đổi của thống kê bậc hai của tín hiệu.

Các lượt quét xen kẽ khai thác trọn vẹn các lần thử ngoại tuyến và không nhân quả, nên ứng dụng trực tuyến sẽ cần xử lý chỉ theo chiều xuôi.

Do IM-TTA, cũng như tham chiếu RA theo từng phiên, sử dụng tín hiệu không nhãn của phiên đánh giá, phương pháp mang tính chuyển nạp và phải được so sánh với các phương pháp cơ sở có cùng mức truy cập dữ liệu đích; ứng dụng trực tuyến sẽ cần ước lượng dần tham chiếu và các thống kê được thích ứng. Các hạn chế khác gồm thiết lập ba kênh của BCI IV-2b, số người tham gia ít của Zhou2016, và các phương pháp cơ sở tương ứng chưa đầy đủ.

6. Kết luận

Chúng tôi đã trình bày SSM-DAN, một khung MI-EEG liên chủ thể kết hợp tích chập đa thang và mô hình không gian trạng thái chọn lọc hai chiều với UDA phân cấp và IM-TTA có ràng buộc, được đánh giá theo giao thức LOSO theo thời gian, giữ nhãn đích nằm ngoài huấn luyện, thích ứng và chọn mô hình. Phương pháp đạt độ chính xác trung bình 76,12% trên BCI IV-2a, 84,09% trên BCI IV-2b và 84,33% trên Zhou2016. Trên tập OpenBMI gồm 54 chủ thể, nghiên cứu loại bỏ thành phần cho thấy tham chiếu RA cần được ước lượng lại trên từng phiên khi năng lượng tín hiệu trôi giữa các phiên. Vẫn cần các phương pháp cơ sở tương ứng và thí nghiệm lặp với nhiều hạt giống trước khi rút ra kết luận rộng hơn.

Đóng góp của tác giả theo CRediT

[**Tên tác giả**]**:** Lên ý tưởng, Phương pháp luận, Phần mềm, Kiểm chứng, Phân tích hình thức, Điều tra, Quản lý dữ liệu, Trực quan hóa, Viết – bản thảo đầu, Viết – rà soát và chỉnh sửa.

Tuyên bố xung đột lợi ích

Các tác giả tuyên bố không có xung đột lợi ích tài chính hay quan hệ cá nhân nào có thể ảnh hưởng đến công trình được báo cáo trong bài báo này.

Tài trợ

Nghiên cứu này không nhận tài trợ cụ thể nào từ các cơ quan tài trợ thuộc khu vực công, thương mại hay phi lợi nhuận.

Tính sẵn có của dữ liệu

Toàn bộ dữ liệu EEG được phân tích trong nghiên cứu này đều công khai. Các bộ dữ liệu BCI Competition IV 2a và 2b [32], bộ dữ liệu Zhou2016 [34] và bộ dữ liệu OpenBMI [40] được truy cập qua thư viện MOABB [31]; không thu thập dữ liệu mới.

Tài liệu tham khảo

[1] G. Pfurtscheller, F. H. Lopes da Silva, Event-related EEG/MEG synchronization and desynchronization: basic principles, Clinical Neurophysiology 110 (11) (1999) 1842–1857. doi:10.1016/S1388-2457(99)00141-8.

[2] F. Lotte, Signal processing approaches to minimize or suppress calibration time in oscillatory activity-based brain–computer interfaces, Proceedings of the IEEE 103 (6) (2015) 871–890. doi:10.1109/JPROC.2015.2404941.

[3] H. Ramoser, J. Müller-Gerking, G. Pfurtscheller, Optimal spatial filtering of single trial EEG during imagined hand movement, IEEE Transactions on Rehabilitation Engineering 8 (4) (2000) 441–446. doi:10.1109/86.895946.

[4] K. K. Ang, Z. Y. Chin, C. Wang, C. Guan, H. Zhang, Filter bank common spatial pattern algorithm on BCI competition IV datasets 2a and 2b, Frontiers in Neuroscience 6 (2012) 39. doi:10.3389/fnins.2012.00039.

[5] R. T. Schirrmeister, J. T. Springenberg, L. D. J. Fiederer, M. Glasstetter, K. Eggensperger, M. Tangermann, F. Hutter, W. Burgard, T. Ball, Deep learning with convolutional neural networks for EEG decoding and visualization, Human Brain Mapping 38 (11) (2017) 5391–5420. doi:10.1002/hbm.23730.

[6] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, B. J. Lance, EEGNet: A compact convolutional neural network for EEG-based brain–computer interfaces, Journal of Neural Engineering 15 (5) (2018) 056013. doi:10.1088/1741-2552/aace8c.

[7] Y. Song, Q. Zheng, B. Liu, X. Gao, EEG Conformer: Convolutional transformer for EEG decoding and visualization, IEEE Transactions on Neural Systems and Rehabilitation Engineering 31 (2023) 710–719. doi:10.1109/TNSRE.2022.3230250.

[8] H. Altaheri, G. Muhammad, M. Alsulaiman, Physics-informed attention temporal convolutional network for EEG-based motor imagery classification, IEEE Transactions on Industrial Informatics 19 (2) (2023) 2249–2258. doi:10.1109/TII.2022.3197419.

[9] H. Altaheri, F. Karray, A.-H. Karimi, Temporal convolutional transformer for EEG based motor imagery decoding, Scientific Reports 15 (1) (2025) 32959. doi:10.1038/s41598-025-16219-7.

[10] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, Attention is all you need, in: Advances in Neural Information Processing Systems, Vol. 30, 2017, pp. 5998–6008.

[11] A. Gu, K. Goel, C. Ré, Efficiently modeling long sequences with structured state spaces, in: International Conference on Learning Representations, 2022.
URL https://openreview.net/forum?id=uYLFoz1vlAC

[12] A. Gu, T. Dao, Mamba: Linear-time sequence modeling with selective state spaces, in: First Conference on Language Modeling, 2024.
URL https://openreview.net/forum?id=tEYskw1VY2

[13] M. Guo, X. Han, H. Liu, J. Zhu, J. Zhang, Y. Bai, G. Ni, MI-Mamba: A hybrid motor imagery electroencephalograph classification model with Mamba's global scanning, Annals of the New York Academy of Sciences 1544 (1) (2025) 242–253. doi:10.1111/nyas.15288.

[14] X. Yang, Z. Jia, Spatial-temporal Mamba network for EEG-based motor imagery classification, in: Advanced Data Mining and Applications, Lecture Notes in Computer Science, Springer Nature Singapore, 2025, pp. 418–432. doi:10.1007/978-981-96-0821-8_28.

[15] W.-B. Jiang, L.-M. Zhao, B.-L. Lu, Large brain model for learning generic representations with tremendous EEG data in BCI, in: International Conference on Learning Representations, 2024.

[16] G. Wang, W. Liu, Y. He, C. Xu, L. Ma, H. Li, EEGPT: Pretrained transformer for universal and reliable representation of EEG signals, in: Advances in Neural Information Processing Systems, Vol. 37, 2024. doi:10.52202/079017-1239.

[17] S. Liu, L. An, C. Zhang, Z. Jia, A spatial-temporal transformer based on domain generalization for motor imagery classification, in: 2023 IEEE International Conference on Systems, Man, and Cybernetics (SMC), 2023, pp. 3789–3794. doi:10.1109/SMC53992.2023.10394657.

[18] X.-C. Zhong, Q. Wang, D. Liu, Z. Chen, J.-X. Liao, J. Sun, Y. Zhang, F.-L. Fan, EEG-DG: A multi-source domain generalization framework for motor imagery EEG classification, IEEE Journal of Biomedical and Health Informatics 29 (4) (2025) 2484–2495, first published online in 2024. doi:10.1109/JBHI.2024.3431230.

[19] Y. Zheng, S. Wu, J. Chen, Q. Yao, S. Zheng, Cross-subject motor imagery electroencephalogram decoding with domain generalization, Bioengineering 12 (5) (2025) 495. doi:10.3390/bioengineering12050495.

[20] M. Long, Y. Cao, J. Wang, M. I. Jordan, Learning transferable features with deep adaptation networks, in: Proceedings of the 32nd International Conference on Machine Learning, Vol. 37 of Proceedings of Machine Learning Research, 2015, pp. 97–105.

[21] Y. Zhao, D. He, F. Ren, Q. Xia, L. Xu, G. Xie, X. Zhang, R. Yang, S. Zou, B. Jiang, RMETNet: A cross-subject motor imagery EEG signal classification model based on TSLANet and Riemannian geometry features, PLOS ONE 21 (4) (2026) e0347671. doi:10.1371/journal.pone.0347671.

[22] Y. Ganin, E. Ustinova, H. Ajakan, P. Germain, H. Larochelle, F. Laviolette, M. Marchand, V. Lempitsky, Domain-adversarial training of neural networks, Journal of Machine Learning Research 17 (59) (2016) 1–35.

[23] X. Tang, X. Zhang, Conditional adversarial domain adaptation neural network for motor imagery EEG decoding, Entropy 22 (1) (2020) 96. doi:10.3390/e22010096.

[24] D. Zhang, H. Li, J. Xie, Unsupervised and semi-supervised domain adaptation networks considering both global knowledge and prototype-based

local class information for motor imagery classification, Neural Networks 179 (2024) 106497. doi:10.1016/j.neunet.2024.106497.

[25] F. M. Carlucci, L. Porzi, B. Caputo, E. Ricci, S. Rota Bulò, AutoDIAL: Automatic DomaIn alignment layers, in: Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017, pp. 5067–5075.

[26] A. Barachant, S. Bonnet, M. Congedo, C. Jutten, Multiclass brain–computer interface classification by Riemannian geometry, IEEE Transactions on Biomedical Engineering 59 (4) (2012) 920–928. doi:10.1109/TBME.2011.2172210.

[27] P. Zanini, M. Congedo, C. Jutten, S. Said, Y. Berthoumieu, Transfer learning: A riemannian geometry framework with applications to brain–computer interfaces, IEEE Transactions on Biomedical Engineering 65 (5) (2018) 1107–1116. doi:10.1109/TBME.2017.2742541.

[28] H. He, D. Wu, Transfer learning for brain–computer interfaces: A euclidean space data alignment approach, IEEE Transactions on Biomedical Engineering 67 (2) (2020) 399–410. doi:10.1109/TBME.2019.2913914.

[29] J. Liang, D. Hu, J. Feng, Do we really need to access the source data? source hypothesis transfer for unsupervised domain adaptation, in: Proceedings of the 37th International Conference on Machine Learning, Vol. 119 of Proceedings of Machine Learning Research, 2020, pp. 6028–6039.

[30] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, T. Darrell, Tent: Fully test-time adaptation by entropy minimization, in: International Conference on Learning Representations, 2021.

[31] V. Jayaram, A. Barachant, MOABB: Trustworthy algorithm benchmarking for BCIs, Journal of Neural Engineering 15 (6) (2018) 066011. doi:10.1088/1741-2552/aadea0.

[32] M. Tangermann, K.-R. Müller, A. Aertsen, N. Birbaumer, C. Braun, C. Brunner, R. Leeb, C. Mehring, K. J. Miller, G. R. Müller-Putz, G. Nolte, G. Pfurtscheller, H. Preissl, G. Schalk, A. Schlögl, C. Vidaurre, S. Waldert, B. Blankertz, Review of the BCI competition IV, Frontiers in Neuroscience 6 (2012) 55. doi:10.3389/fnins.2012.00055.

[33] R. Leeb, F. Lee, C. Keinrath, R. Scherer, H. Bischof, G. Pfurtscheller, Brain–computer communication: Motivation, aim, and impact of exploring a virtual apartment, IEEE Transactions on Neural Systems and Rehabilitation Engineering 15 (4) (2007) 473–482. doi:10.1109/TNSRE.2007.906956.

[34] B. Zhou, X. Wu, Z. Lv, L. Zhang, X. Guo, A fully automated trial selection method for optimization of motor imagery based brain–computer interface, PLOS ONE 11 (9) (2016) e0162657. doi:10.1371/journal.pone.0162657.

[35] W. Liao, H. Liu, W. Wang, Advancing BCI with a transformer-based model for motor imagery classification, Scientific Reports 15 (1) (2025) 23380. doi:10.1038/s41598-025-06364-4.

[36] T. Miao, L. Sha, K. Huang, Y. Li, B. Liu, SATrans-Net: Sparse attention transformer for EEG-based motor imagery decoding, Scientific Reports 16 (1) (2025) 1192. doi:10.1038/s41598-025-30806-8.

[37] S. Li, Z. Wang, H. Luo, L. Ding, D. Wu, T-TIME: Test-time information maximization ensemble for plug-and-play BCIs, IEEE Transactions on Biomedical Engineering 71 (2) (2024) 423–432. doi:10.1109/TBME.2023.3303289.

[38] S. Li, J. Ouyang, Z. Cui, Z. Wang, T. Jia, F. Wan, D. Wu, Backpropagation-free test-time adaptation for lightweight EEG-based brain–computer interfaces, IEEE Journal of Biomedical and Health Informatics (2026). doi:10.1109/JBHI.2026.3725326.

[39] J. R. Wolpaw, N. Birbaumer, D. J. McFarland, G. Pfurtscheller, T. M. Vaughan, Brain–computer interfaces for communication and control, Clinical Neurophysiology 113 (6) (2002) 767–791. doi:10.1016/S1388-2457(02)00057-3.

[40] M.-H. Lee, O.-Y. Kwon, Y.-J. Kim, H.-K. Kim, Y.-E. Lee, J. Williamson, S. Fazli, S.-W. Lee, EEG dataset and OpenBMI toolbox for three BCI paradigms: an investigation into BCI illiteracy, GigaScience 8 (5) (2019) giz002. doi:10.1093/gigascience/giz002.